

Módulo 5: Aprendizaje no supervisado

Métodos de Muestreo, 1ra Parte

Diplomatura Cs. de Datos - FaCENA-UNNE

Docentes: Magdalena Lucini, Luis Duarte, Griselda Bóbeda

Generación números aleatorios

Supongamos se quiere generar números aleatorios (o pseudoaleatorios). En python, por ejemplo, se puede usar la librería `random` donde, entre otras, se tiene las siguientes funciones:

- `randrange(a, b[, step])`: devuelve un número aleatorio entre a y b con un salto de tamaño $step$
- `randint(a, b)`: retorna un entero aleatorio z tal que $a \leq z \leq b$
- `uniform(a, b)`: devuelve un número real entre a y b .

Generación de distribuciones

En numerosas aplicaciones, métodos y técnicas usadas en machine learning, ciencias de datos y estadística, necesitaremos generar realizaciones de variables aleatorias que siguen alguna distribución probabilística.

Por ejemplo:

- Generar realizaciones (muestras) $x_i, i = 1, \dots, n$ de una variable aleatoria X con distribución F_X para poder estimar el/los parámetros de esa distribución.
- Calcular (aproximar) la esperanza de una función $f(z)$ con respecto a una distribución de probabilidades $p(z)$ (discreta o continua).
$$E[f] = \int (f(z)p(z)dz, \hat{f} = \frac{1}{L} \sum_{i=1}^L f(z^i), E[\hat{f}] = E[f]$$
- Generar muestras de una probabilidad a posteriori $p(z/\mathcal{D})$ para luego calcular (aproximar) probabilidades marginales, esperanzas, etc.

Métodos de muestreo numérico

- **Objetivo:** generar eficientemente muestras de una distribución , aún en altas dimensiones. Esto es, generar números aleatorios que se distribuyan según una determinada densidad $p_o(z)$, denominada **densidad objetivo**.
- Basados en la idea de aproximaciones Monte Carlo
- Cada uno de los algoritmos asume disponible una fuente de números aleatorios con densidad $t(z)$, denominada **densidad propuesta** y convierte muestras de $t(z)$ a muestras de $p_o(z)$.
- Generando la cantidad de muestras suficientes se puede alcanzar el nivel de precisión deseado.

Diferentes técnicas de muestreo

Métodos directos

- Se generan muestras de números aleatorios cuya densidad es la densidad propuesta, y se usa una transformación adecuada para obtener muestras de la densidad objetivo.
- En general, son métodos rápidos y las muestras son independientes (tan independientes como las generadas por la distribución propuesta).
- Difícilmente aplicables en la práctica pues no es simple encontrar la transformación adecuada.

Diferentes técnicas de muestreo

Métodos de aceptación -rechazo

- Se generan muestras de números aleatorios cuya densidad es la densidad propuesta (disponible), y el algoritmo acepta o rechaza esas muestras mediante un test.
- Las muestras son independientes (tan independientes como las generadas por la distribución propuesta).
- Costo computacional alto si la tasa de aceptación es baja (probabilidad baja de aceptar la muestra)

Diferentes técnicas de muestreo

Importance sampling

- Se asignan pesos a las muestras generadas por la densidad propuesta para obtener una aproximación de la probabilidad representada por la densidad objetivo.
- La aproximación a la densidad objetivo lograda con este método , junto a los principios básicos de MCMC puede ser usada como generador de números aleatorios.

MCMC: Markov Chain Monte Carlo

- Técnicas basadas en la construcción de una cadena de Markov que converge a la densidad objetivo.
- En general, son ,métodos “universales”, ya que se pueden aplicar en casi cualquier caso.
- Las muestras no necesariamente serán independientes

Métodos Directos

Consideremos una variable aleatoria X con función de densidad objetivo $p_o(x)$, con función de distribución acumulada $F_X(x)$.

Método de Inversión - distribuciones “simples”

Si $U \sim \mathcal{U}[0, 1]$, entonces la variable aleatoria $Z = F_X^{-1}(U)$ tiene densidad $p_o(x)$

Algorithm 1 Método de inversión

generar $u_i \sim \mathcal{U}(0, 1)$
devolver $z_i = F_X^{-1}(u_i)$

Ejemplo: Simulación distribución exponencial

Si $X \sim \mathcal{E}(\lambda) \Rightarrow$

$$F_X(x) = 1 - e^{-\lambda x}, \quad \text{si } x \geq 0$$

Como

$$1 - e^{-\lambda x} = u \Leftrightarrow x = -\frac{\ln(1-u)}{\lambda}$$

Figure: 1000 muestras $\mathcal{U}(0,1)$

generar $u_i \sim \mathcal{U}(0,1)$
devolver $x_i = -\frac{\ln(1-u_i)}{\lambda}$

Figure: 1000 muestras exponencial,
 $\lambda = 5$

No siempre es posible encontrar la expresión analítica de F_X^{-1}

Ejemplo: Simulación distribución exponencial

Si $X \sim \mathcal{E}(\lambda) \Rightarrow$

$$F_X(x) = 1 - e^{-\lambda x}, \quad \text{si } x \geq 0$$

Como

$$1 - e^{-\lambda x} = u \Leftrightarrow x = -\frac{\ln(1-u)}{\lambda}$$

Figure: 1000 muestras $\mathcal{U}(0,1)$

generar $u_i \sim \mathcal{U}(0,1)$
devolver $x_i = -\frac{\ln(1-u_i)}{\lambda}$

Figure: 1000 muestras exponencial,
 $\lambda = 5$

No siempre es posible encontrar la expresión analítica de F_X^{-1}

Ejemplo: Simulación distribución exponencial

Si $X \sim \mathcal{E}(\lambda) \Rightarrow$

$$F_X(x) = 1 - e^{-\lambda x}, \quad \text{si } x \geq 0$$

Como

$$1 - e^{-\lambda x} = u \Leftrightarrow x = -\frac{\ln(1-u)}{\lambda}$$

generar $u_i \sim \mathcal{U}(0, 1)$
devolver $x_i = -\frac{\ln(1-u_i)}{\lambda}$




Figure: 1000 muestras $\mathcal{U}(0, 1)$




Figure: 1000 muestras exponencial,
 $\lambda = 5$

No siempre es posible encontrar la expresión analítica de F_X^{-1}

Ejemplo: Simulación distribución exponencial

Si $X \sim \mathcal{E}(\lambda) \Rightarrow$

$$F_X(x) = 1 - e^{-\lambda x}, \quad \text{si } x \geq 0$$

Como

$$1 - e^{-\lambda x} = u \Leftrightarrow x = -\frac{\ln(1-u)}{\lambda}$$

generar $u_i \sim \mathcal{U}(0, 1)$
devolver $x_i = -\frac{\ln(1-u_i)}{\lambda}$




Figure: 1000 muestras $\mathcal{U}(0, 1)$




Figure: 1000 muestras exponencial,
 $\lambda = 5$

No siempre es posible encontrar la expresión analítica de F_X^{-1}

Método de Inversión

Nombre	Densidad	$F(x)$	$F^{-1}(U)$	Forma simplificada
$\exp(\lambda) \ (\lambda > 0)$	$\lambda e^{-\lambda x}, \text{ si } x \geq 0$	$1 - e^{-\lambda x}$	$-\frac{\ln(1 - U)}{\lambda}$	$-\frac{\ln U}{\lambda}$
Cauchy	$\frac{1}{\pi(1 + x^2)}$	$\frac{1}{2} + \frac{\arctan x}{\pi}$	$\tan\left(\pi\left(U - \frac{1}{2}\right)\right)$	$\tan \pi U$
Triangular en $(0, a)$	$\frac{2}{a}\left(1 - \frac{x}{a}\right), \text{ si } 0 \leq x \leq a$	$\frac{2}{a}\left(x - \frac{x^2}{2a}\right)$	$a(1 - \sqrt{1 - U})$	$a(1 - \sqrt{U})$
Pareto ($a, b > 0$)	$\frac{ab^a}{x^{a+1}}, \text{ si } x \geq b$	$1 - \left(\frac{b}{x}\right)^a$	$\frac{b}{(1 - U)^{1/a}}$	$\frac{b}{U^{1/a}}$
Weibull ($\lambda, \alpha > 0$)	$\alpha \lambda^\alpha x^{\alpha-1} e^{-(\lambda x)^\alpha}, \text{ si } x \geq 0$	$1 - e^{-(\lambda x)^\alpha}$	$\frac{(-\ln(1 - U))^{1/\alpha}}{\lambda}$	$\frac{(-\ln U)^{1/\alpha}}{\lambda}$

Muestreo de aceptación - rechazo (rejection sampling) Von Neuman, 1951

- Método universal: en principio puede usarse para generar muestras de cualquier tipo de densidad objetivo $p_o(x)$.
- Se considera una función de densidad de probabilidad (fdp) propuesta $t(x)$ fácil de muestrear.
- Se elige una constante C tal que la curva $Ct(x)$ está siempre por encima de la curva de $p_o(x)$, i.e,

$$Ct(x) \geq p_o(x), \forall x \in \mathcal{S}$$

con \mathcal{S} dominio de $p_o(x)$.

- Se genera una muestra $x' \sim t$, y se calcula $p_A(x') = \frac{p_o(x')}{Ct(x')}$ que es la probabilidad de aceptar esa muestra.
- Se genera $u' \sim \mathcal{U}(0, 1)$. Si $u' \leq p_A(x') \Rightarrow$ se acepta x' , caso contrario se la descarta.

Método de aceptación-rechazo

Algorithm 2 Método de aceptación-rechazo

generar $u \sim \mathcal{U}(0, 1)$

generar $x \sim t$

if $u \leq \frac{p_o(x)}{Ct(x)}$ **then**

 aceptar x como muestra

else

 rechazar x como muestra y volver al punto inicial

end if

Ejemplo método de aceptación-rechazo

$$p_o(x) = 30x(1-x)^4, 0 \leq x \leq 1$$

$$t(x) = 2.5 \quad 0 \leq x \leq 1 \text{ mayoriza a } p_o(x)$$


NO es fdp

$$r(x) = t(x)/k : k = \int_{-\infty}^{\infty} t(x)dx$$

$$r(x) = 1, 0 \leq x \leq 1$$

$$F_r(x) = x, 0 \leq x \leq 1$$

Si es fdp



Pasos

- 1 Generar x al “azar”. ¿Cómo?
- 2 $P(\text{aceptar } x) = \frac{p_o(x)}{t(x)}$
- 3 Generar $u_x \sim \mathcal{U}(0, 1)$
- 4 Si $u_x \leq P(\text{aceptar } x) \rightarrow$ devolver x
Si $u_x > P(\text{aceptar } x) \rightarrow$ ir a 1

Ejemplo método de aceptación-rechazo

$$p_o(x) = 30x(1-x)^4, 0 \leq x \leq 1$$

$$t(x) = 2.5 \quad 0 \leq x \leq 1 \text{ majoriza a } p_o(x)$$


NO es fdp

$$r(x) = t(x)/k : k = \int_{-\infty}^{\infty} t(x)dx$$

$$r(x) = 1, 0 \leq x \leq 1$$

$$F_r(x) = x, 0 \leq x \leq 1$$

Si es fdp



Pasos

- 1 Generar x al “azar”. ¿Cómo?
- 2 $P(\text{aceptar } x) = \frac{p_o(x)}{t(x)}$
- 3 Generar $u_x \sim \mathcal{U}(0, 1)$
- 4 Si $u_x \leq P(\text{aceptar } x) \rightarrow$ devolver x
Si $u_x > P(\text{aceptar } x) \rightarrow$ ir a 1

Ejemplo método de aceptación-rechazo

$$p_o(x) = 30x(1-x)^4, 0 \leq x \leq 1$$


$$r(x) = \frac{t(x)}{k}$$

$$F_r(x) = x, 0 \leq x \leq 1$$

Transformada Inversa $x = F_r^{-1}(u_r)$,

$$0 \leq u_r \leq 1$$


$$u_r \sim \mathcal{U}(0,1)$$



Pasos

- 1 Generar $u_r \sim \mathcal{U}(0,1)$
Generar $x \sim r(x)$ usando u_r
- 2 $P(\text{aceptar } x) = \frac{p_o(x)}{t(x)}$
- 3 Generar $u_x \sim \mathcal{U}(0,1)$
- 4 Si $u_x \leq P(\text{aceptar } x) \rightarrow$ devolver x
Si $u_x > P(\text{aceptar } x) \rightarrow$ ir a 1

Ejemplo método de aceptación-rechazo




Pasos

- 1 Generar $u_r \sim \mathcal{U}(0, 1)$
Generar $x \sim r(x)$ usando u_r
- 2 $P(\text{aceptar } x) = \frac{p_o(x)}{t(x)}$
- 3 Generar $u_x \sim \mathcal{U}(0, 1)$
- 4 Si $u_x \leq P(\text{aceptar } x) \rightarrow$
devolver x
Si $u_x > P(\text{aceptar } x) \rightarrow$ ir a 1

Pasos


- 1 $u_r = 0.5$
 $x = 0.5$
- 2 $P(\text{aceptar } x) = \frac{0.9375}{2.5} = 0.375$
- 3 $u_x = 0.6$
- 4 rechaza x y vuelve al punto 1

Ejemplo método de aceptación-rechazo



Pasos

- 1 Generar $u_r \sim \mathcal{U}(0, 1)$
Generar $x \sim r(x)$ usando u_r
- 2 $P(\text{aceptar } x) = \frac{p_o(x)}{t(x)}$
- 3 Generar $u_x \sim \mathcal{U}(0, 1)$
- 4 Si $u_x \leq P(\text{aceptar } x) \rightarrow$
devolver x
Si $u_x > P(\text{aceptar } x) \rightarrow$ ir a 1




Pasos

- 1 $u_r = 0.5$
 $x = 0.5$
- 2 $P(\text{aceptar } x) = \frac{0.9375}{2.5} = 0.375$
- 3 $u_x = 0.6$
- 4 **rechaza x y vuelve al punto 1**

Método de aceptación -rechazo

- Puede demostrarse que la $P(\text{Aceptar } X) = 1/C$ y está relacionado con la elección de la función $t(x)$
- Lo ideal es elegir $t(x)$ lo más parecida posible a $p_o(x)$



$$\hat{\mathbb{E}}_p[X] = \frac{1}{N} \sum_{i=1}^N x^i = 55.27$$




Muestreo por Importancia (importance sampling)

- Proveen de un marco estadístico para aproximar momentos (esperanzas, varianzas) bajo una distribución $p_o(x)$ cuando no es posible muestrearla directamente.
- NO es un método para generar muestras de la fdp objetivo p_o .
- En el muestreo por importancia se asocian pesos a las muestras producidas por la densidad propuesta $t(x)$
- Estos pesos representan la **importancia** estadística de la muestra
- Los pesos son $w(x') = \frac{p_o(x')}{t(x')} \propto \frac{p(x')}{t(x')}$, donde $p(x) \propto p_o(x)$
- La **importancia** es:
 - ▶ directamente proporcional a $p(x)$: mientras más alto el valor de $p_o(x')$, más mas de probabilidad estará concentrada alrededor de x' y por ende hay que darle más **importancia** a esa muestra.
 - ▶ inversamente proporcional a $t(x)$: si $t(x')$ es bajo, la probabilidad de proponer otra muestra x' es baja, por lo que hay que darle **importancia** a esa muestra.

Muestreo por importancia

Situaciones en muestreo por importancia

- $p(x')$ alto, $t(x')$ bajo: la **importancia** $w(x')$ será grande (Fig a).
- $p(x') \approx t(x')$ la **importancia** $w(x') \approx 1$ (Fig b)
- $p(x')$ bajo, $t(x')$ alto: la **importancia** $w(x')$ será pequeña. (Fig c)
- En general, los pesos miden cuán distintas son las fdp objetivo y propuesta.



Muestreo por Importancia

$$\begin{aligned}\mathbb{E}_p[f(X)] &= \int_{-\infty}^{\infty} f(x) p_o(x) dx \\&= \int_{-\infty}^{\infty} f(x) \frac{p_o(x)}{t(x)} t(x) dx \\&= \int_{-\infty}^{\infty} \left(\frac{f(x) p_o(x)}{t(x)} \right) t(x) dx \\&= \mathbb{E}_t \left[\frac{f(Y) p_o(Y)}{t(Y)} \right]\end{aligned}$$

$$\begin{aligned}\hat{\mathbb{E}}_p[f(X)] &= \hat{\mathbb{E}}_t \left[\frac{f(Y) p_o(Y)}{t(Y)} \right] \\&= \frac{1}{N} \sum_{i=1}^N \frac{f(x^i) p_o(x^i)}{t(x^i)}\end{aligned}$$

Puede ser necesario normalizar la fdp objetivo

Muestreo por importancia

Método más general (no se conocen constantes de normalización)

Algorithm 3 Muestreo por importancia

1. generar N muestras x^i , $i = 1, \dots, N$ de la fdp propuesta $t(x)$
2. asociar pesos a cada uno de los x^i haciendo


$$w_i = \frac{p(x^i)}{t(x^i)}$$

, con $p(x) \propto p_o(x)$

3. normalizar los pesos $\tilde{w}_i = \frac{w_i}{\sum_{k=1}^N w_k}$, $i = 1, \dots, N$

4. Se aproxima a $p_o(x)$ usando $\tilde{h}_N(x) = \sum_{i=1}^N \tilde{w}_i \delta(x - x^i)$
-


Cálculo de esperanzas usando Muestreo por Importancia



- $p_o(x)$ fdp
 $\mathcal{N}(30, 10) + \mathcal{N}(80, 20)$, $t(x)$ fdp
 $\mathcal{N}(50, 30)$
- X con fdp $p_o(x)$
- $N = 5000$
- generar 5000 muestras de $t(x)$
- calcular pesos
- $\hat{\mathbb{E}}[X] = \sum_{i=1}^N \tilde{w}_i x^i = 50$

La elección de la densidad propuesta afecta al desempeño de este método

Cálculo de esperanzas usando Muestreo por Importancia



- $p_o(x)$ fdp
 $\mathcal{N}(30, 10) + \mathcal{N}(80, 20)$, $t(x)$ fdp
 $\mathcal{N}(50, 30)$
- X con fdp $p_o(x)$
- $N = 5000$
- generar 5000 muestras de $t(x)$
- calcular pesos
- $\hat{\mathbb{E}}[X] = \sum_{i=1}^N \tilde{w}_i x^i = 50$

La elección de la densidad propuesta afecta al desempeño de este método

Sampling Importance Resampling (SIR)

- El éxito de los métodos de rechazo depende en parte de la elección de la constante C
- Para muchos pares de combinaciones de fdp objetivo y propuesta se dificulta encontrar una constante C que sea lo suficientemente grande para acotar la distribución objetivo y a la vez garantizar una alta tasa de aceptación.
- El método **Sampling Importance Resampling** (SIR) hace uso de la fdp propuesta t para generar muestras de la fdp objetivo p_o , pero evita el paso de determinar la constante C .
- Básicamente consiste de dos pasos: **generación** de muestras en el primer paso, mientras que en el segundo se calculan pesos como en el muestreo por **importancia** y se genera (**resampling**) un segundo conjunto de muestras usando esos pesos.
- Las muestras resultantes se utilizan para aproximar p_o . La aproximación es buena para muestras grandes ($N \rightarrow \infty$)

Sampling Importance Resampling

Objetivo: generar muestras de la fdp objetivo p_o .

Algorithm 4 SIR

1. generar N muestras y^i , $i = 1, \dots, N$ de la fdp propuesta t
2. calcular los pesos

$$w_i = \frac{p_o(y^i)}{t(y^i)}$$

y normalizarlos $\tilde{w}_i = \frac{w_i}{\sum_{k=1}^N w_k}$, $i = 1, \dots, N$

3. Para $i = 1, \dots, N$ se elige un nuevo conjunto de muestras (x^1, \dots, x^N) (con reemplazo) usando los pesos como probabilidades:

$$x^i = \begin{cases} y^1 & \text{con probabilidad } \tilde{w}_1 \\ \vdots & \vdots \\ y^N & \text{con probabilidad } \tilde{w}_N \end{cases}$$

Aplicación SIR: Ejercicio

Objetivo: Generar muestras de una variable aleatoria con fdp objetivo p_o definida como la suma de gaussianas $\mathcal{N}(30, 10) + \mathcal{N}(80, 20)$

Usar como fdp propuesta:

- 1 t_1 fdp de una variable uniforme en $\mathcal{U}(0, 110)$
- 2 t_2 fdp de $\mathcal{N}(50, 30)$.